Consumo de tokens

Generación comparable: semántica frente a híbrida

MEDICIÓN COMPLETA | Desarrollo | Revisión humana pendiente

Dato	Condición
Modelo	openai/gpt-oss-20b
Prompt / parámetros	rag_v6 / temperatura 0 / reasoning low / salida máxima 800 tokens
Muestra	7 preguntas documentales; dos variantes; 7 pares con usage válido
Alcance	Generación directa únicamente; excluye clasificación, revisión y corrección. Reserva sin ejecutar.

1. Tokens informados por Groq

Medida	A: Semántica	B: Híbrida v2	Diferencia B-A
Entrada: media	764,86	769,71	4,86
Salida: media	176,86	162,14	-14,71
Total: media	941,71	931,86	-9,86
Entrada: suma emparejada	5.354,00	5.388,00	34,00
Salida: suma emparejada	1.238,00	1.135,00	-103,00
Total: suma emparejada	6.592,00	6.523,00	-69,00

Usage real del proveedor; no son estimaciones del tokenizer. Salida puede incluir razonamiento interno. Menos tokens no acredita mayor fidelidad o utilidad. No se calcula costo monetario.

2. Integridad de la medición

Registro	A: Semántica	B: Híbrida v2
Observaciones, incluidos reintentos explícitos	7	7
Respuestas HTTP recibidas	7	7
Observaciones sin usage válido	0	0
Salidas con contrato y citas válidos	7	7

La comparación utiliza exactamente los mismos casos con usage válido en ambas variantes. Un error o usage ausente no se convierte en cero. El JSON conserva todas las observaciones; su contabilidad global incluye tokens conocidos aunque la salida no cumpla el contrato.

3. Registro por pregunta y variante

Caso	Variante	Entrada	Salida	Total	Contrato / estado
E01	A: Semántica	784	132	916	contract_valid
E01	B: Híbrida v2	785	165	950	contract_valid
E02	A: Semántica	772	225	997	contract_valid
E02	B: Híbrida v2	770	157	927	contract_valid
E03	A: Semántica	763	177	940	contract_valid
E03	B: Híbrida v2	760	212	972	contract_valid
E04	A: Semántica	759	132	891	contract_valid
E04	B: Híbrida v2	764	110	874	contract_valid
E05	A: Semántica	757	192	949	contract_valid
E05	B: Híbrida v2	781	187	968	contract_valid
E06	A: Semántica	756	196	952	contract_valid
E06	B: Híbrida v2	757	193	950	contract_valid
E12	A: Semántica	763	184	947	contract_valid
E12	B: Híbrida v2	771	111	882	contract_valid

contract_valid solo comprueba JSON, contrato y coherencia de etiquetas con el catálogo. No prueba respaldo semántico, corrección, conservación de condiciones ni utilidad. Las respuestas y contextos quedan en JSON para la siguiente revisión humana.

4. Preguntas y protocolo

Caso	Pregunta
E01	Mi portátil no enciende y sale olor a quemado. ¿Qué indica el manual?
E02	El instalador de una aplicación autorizada pide privilegios de administrador que no tengo. ¿Debo desactivar los controles de seguridad para instalarla?
E03	No puedo conectarme al Wi-Fi corporativo. ¿Qué comprobaciones iniciales indica el manual?
E04	Olvidé mi contraseña del Portal TI simulado y todavía tengo acceso al correo registrado. ¿Cómo la recupero?
E05	Recibí un correo sospechoso con un enlace que pide mi contraseña. No he abierto el enlace. ¿Qué debo hacer según el manual?
E06	El portal de documentos devuelve error 403. ¿Eso demuestra que mi cuenta está suspendida? ¿Qué debe revisar soporte?
E12	¿Qué comprobaciones iniciales recomienda el manual para una impresora?

Mismo modelo, prompt, esquema, temperatura, límite de salida y presupuesto de contexto para ambas estrategias. A usa los Top-10 semánticos guardados; ambas aplican la política de pertinencia antes de Top-3. B usa la selección híbrida mejorada. No se alimentan categorías esperadas al generador.

Orden alternado A/B y B/A entre preguntas. Una observación por combinación; no acredita estabilidad estadística ni generalización. Son preguntas conocidas de desarrollo, con anotaciones pendientes de revisión humana.

La estimación local de entrada se conserva separada del usage real. Sin clasificación, revisor ni corrección, esta medición no equivale al consumo total de la API query. Los reintentos explícitos permanecen en el historial; uso desconocido permanece desconocido.

Trazabilidad

Creación UTC: 2026-10-21T16:13:59.935282+00:00

SHA-256 fuente de recuperación: ff5ac34198de6aedea96849831ad5535f2cc6080040282705d08c4107c6f4406

SHA-256 prompt: 4422bcc41779dfcf7b4c6bec204a750b1386e1bd0f34bc202e21853d50c5621b

JSON: generation_tokens_20261021.json

SHA-256 JSON: d08dc1db1a61fe63e7b6d9e94035ce575cd9a8500c9f285ea74457c1a55eee2d